Big Data Analytics

Introdução ao uso do R / RStudio

Agenda

- Histórico e motivação;
- Instalar a linguagem R e o RStudio;
- Compreender conceitualmente a linguagem R;
- Identificar os objetos do R.

Histórico e motivação

Um pouco de história

- O principal objetivo da linguagem R é analisar dados.
- Criadores: Ross Ihaka e Robert Gentleman, membros do departamento de Estatística da Universidade de Auckland, Nova Zelândia.

Um pouco de história

- A linguagem R recebeu este nome por ser baseada na linguagem S, desenvolvida no AT&T Bell Labs, e como homenagem aos dois criadores, ambos com nomes que iniciam pela mesma letra.
- É uma linguagem de programação interpretada, voltada para a manipulação de dados e apresentação gráfica de resultados.

Linguagem S

- Linguagem de programação estatística criada por John M. Chambers com participação de Rick Becker e Allan Wilks em suas versões iniciais. Todos trabalhavam na Bell Laboratories.
- Criada entre 1975 e 1976.
- As implementações modernas são:
  - R;
  - S-Plus.

A linguagem R

- A linguagem R é *open source*. Seu código fonte está sob a *Free Software Foundation's GNU General Public License.*
- Criada entre o final dos anos 1990 e o início dos anos 2000.
- Versões para diversos sistemas operacionais, sem alterações significativas:
  - Windows;
  - MacOS;
  - Linux.

A linguagem R

- É mais do que um software estatístico:
  - Ambiente que permite explorar dados interativamente;
  - À medida que a análise evolui, é uma linguagem de programação completa para desenvolver e automatizar soluções e/ou desenvolver pacotes de expansão que abordem necessidades específicas;
  - Ferramenta poderosa para manipulação, processamento, visualização e análise de dados, bem como simulações e modelagem estatísticas.

A linguagem R

- Grande e ativa comunidade de usuários;
  - Empresas:
    - Google;
    - AT&T;
    - Empresas da área de investimento e finanças.
  - Academia:
    - Laboratórios;
    - Centros de pesquisa;
    - Professores de diversas universidades espalhadas pelo mundo.
- Mais de 4.000 pacotes gratuitos e abertos para download.

Exemplos

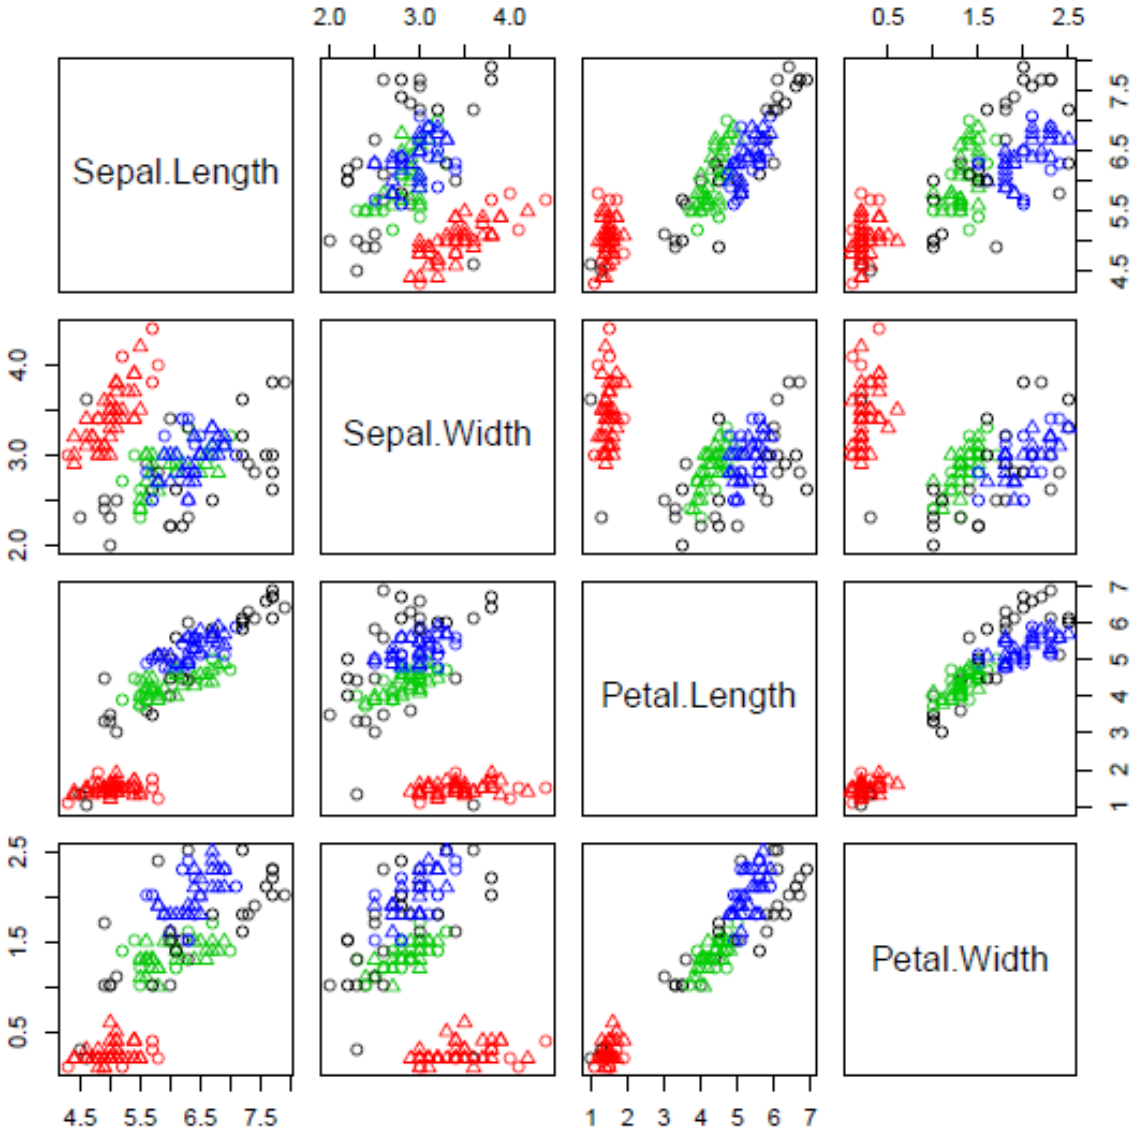
Sepal.Length
Sepal.Width
Petal.Length
Petal.Width
2.0
3.0
4.0
0.5
1.5
2.5
4.5
5.5
6.5
7.5
1
2
3
4
5
6
7

Exemplos

Exemplos

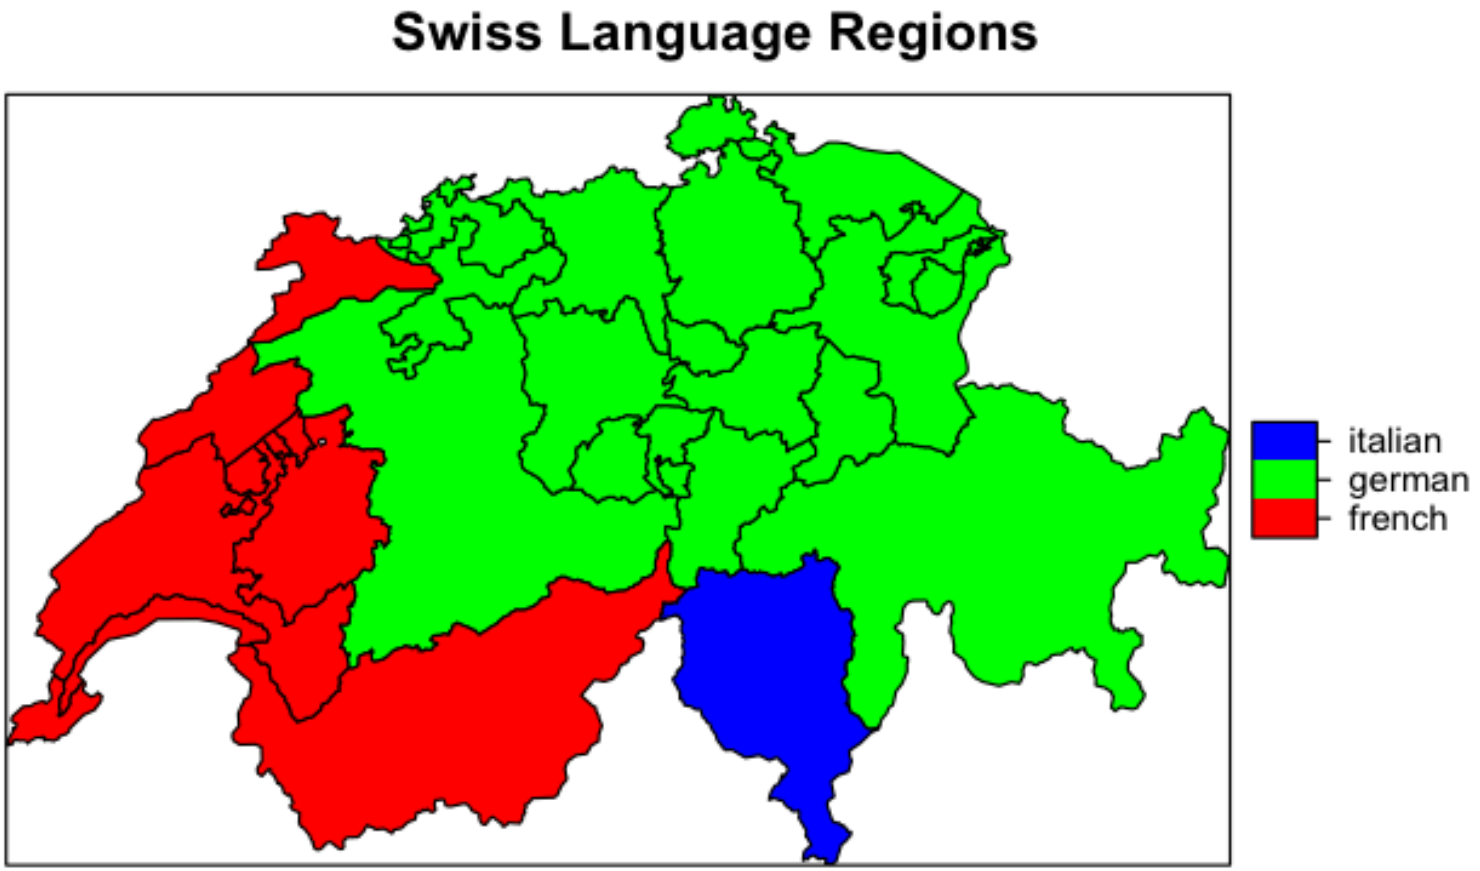

Exemplos

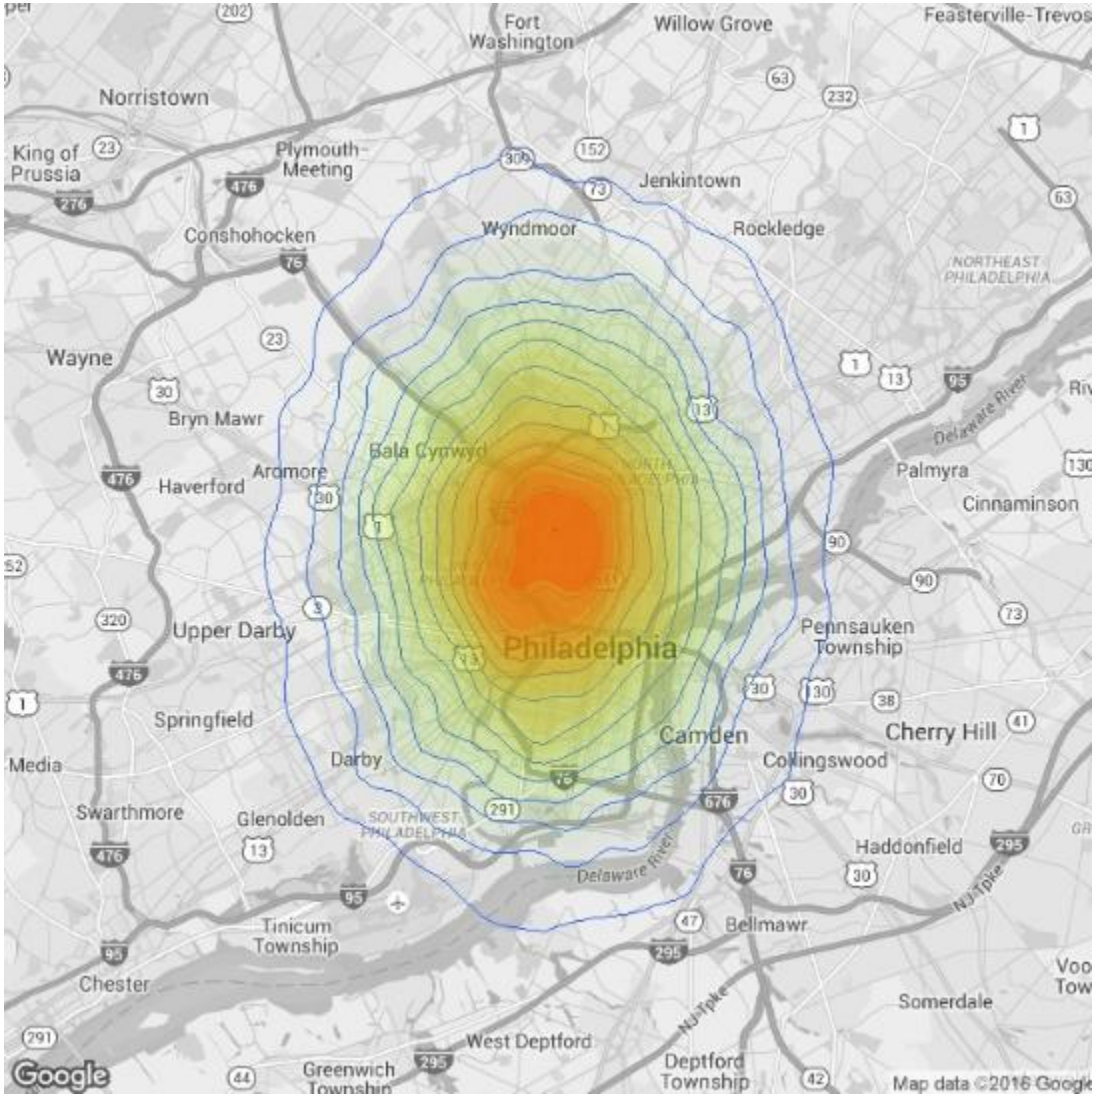

Exemplos

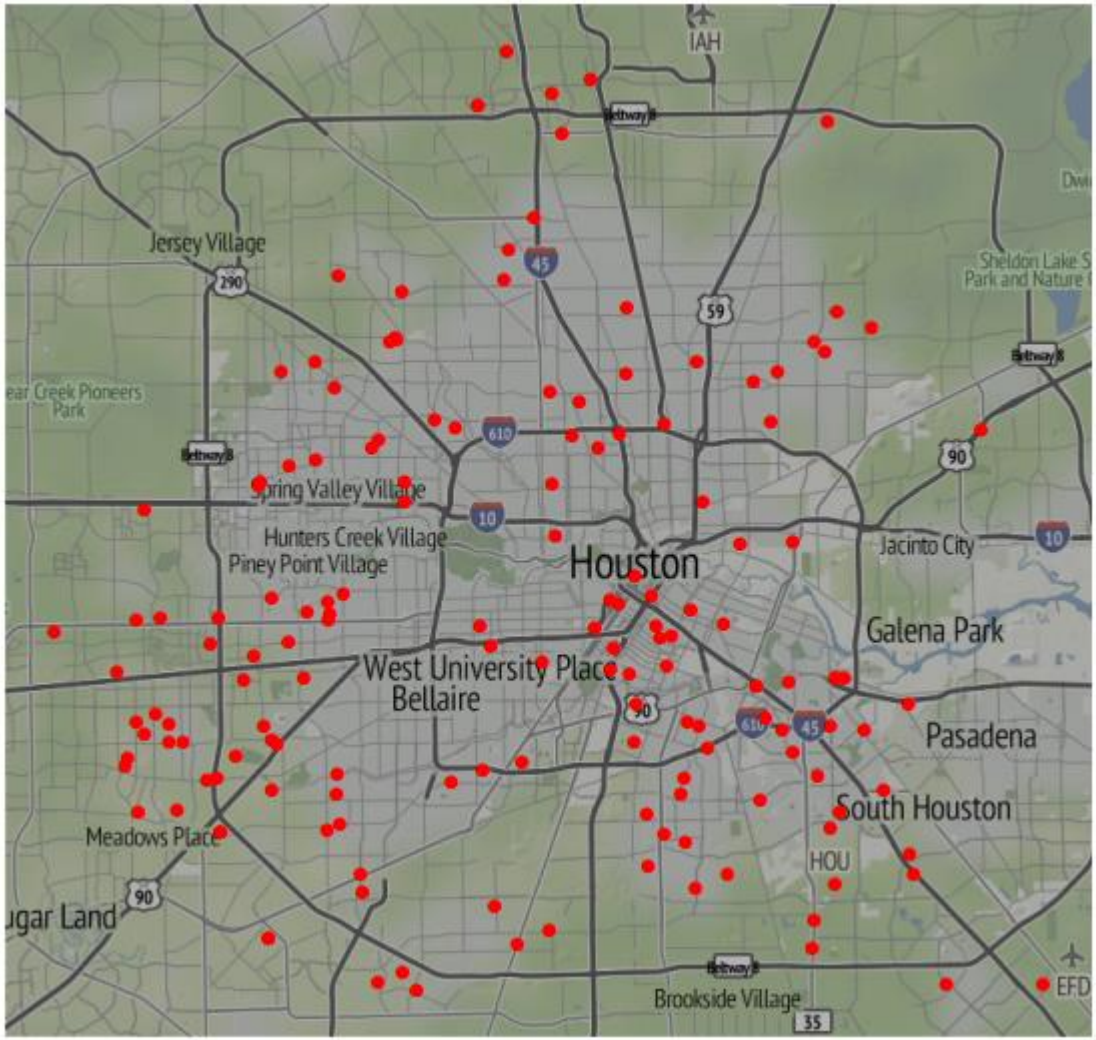

Exemplos

Exemplos

Exemplos

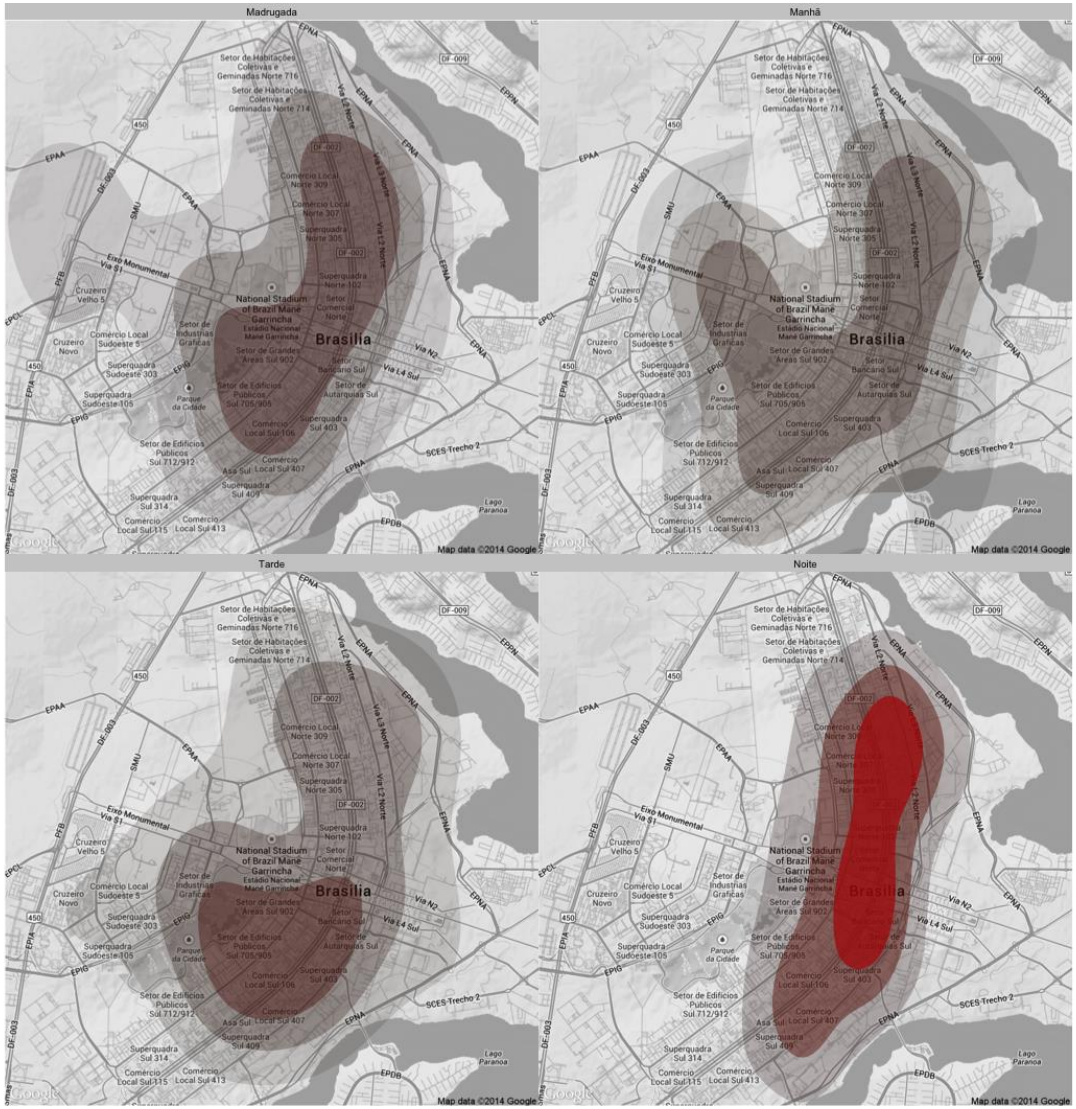
Madrugada
Manhã
Tarde
Noite
Brasília
National Stadium of Brazil Mané Garrincha
Map data ©2014 Google

Exemplos

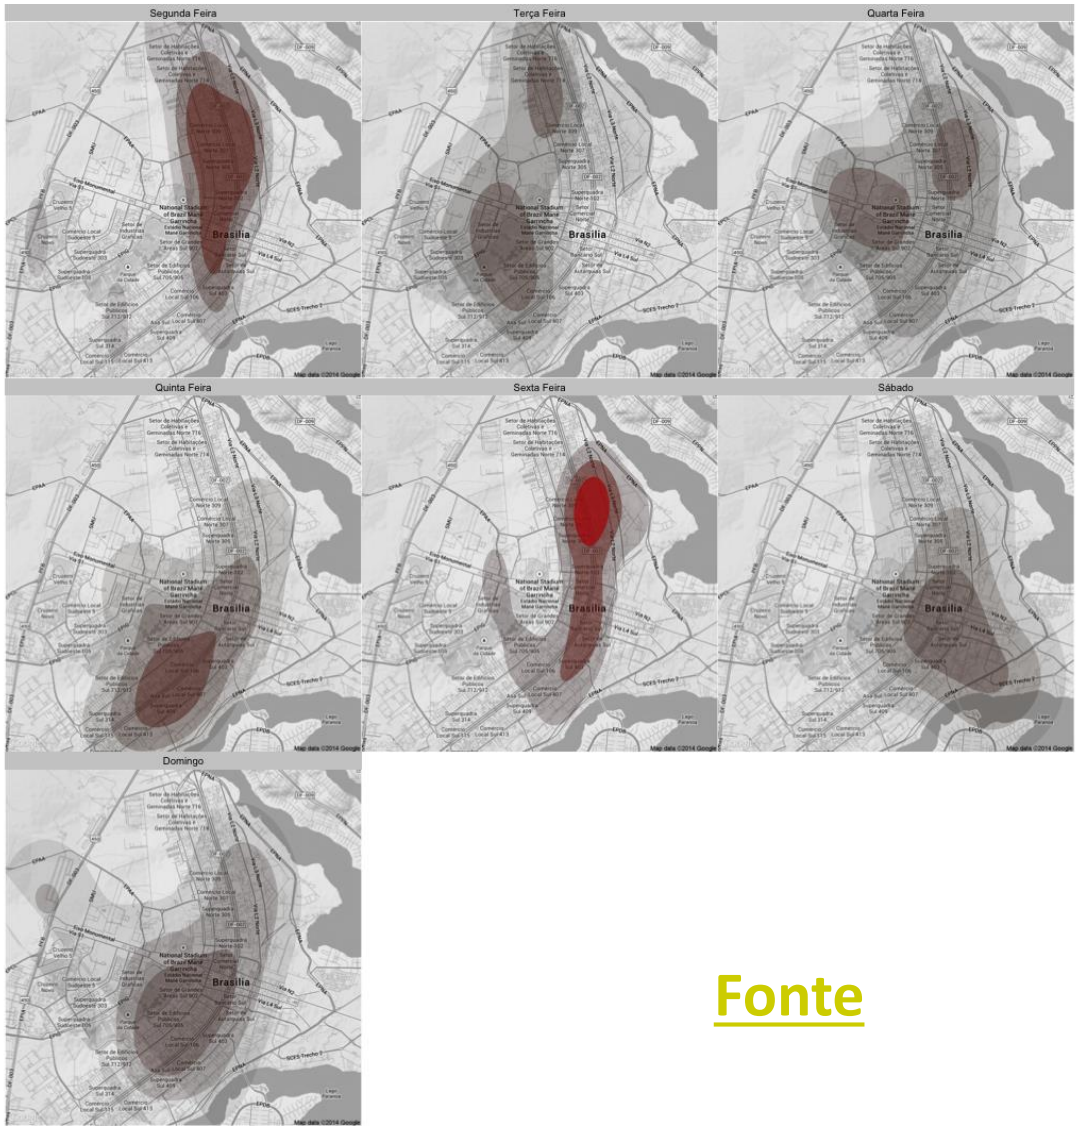

Fonte

Instalar a linguagem R e o RStudio

Instalação

- Os sites principais relacionados à linguagem R são os seguintes:
  - The R Project for Statistical Computing
    - Site oficial do projeto R.
  - The Comprehensive R Archive Network
    - (CRAN) Repositório de arquivos para instalação da ferramenta e bibliotecas de apoio.

Instalação

- Faça o download da instalação principal do *mirror* (espelho) do CRAN, localizado na Fundação Oswaldo Cruz.
  - Download and Install R

- Uma outra opção é o Microsoft R, que traz algumas melhorias em relação à *engine* R padrão (pacotes *multithread* nativos, dentre outras), sendo totalmente compatível com a *engine* R padrão.

32 ou 64 Bits?

- Para a maioria dos usuários, a instalação em modo nativo é a recomendada (de acordo com o sistema operacional).
- Informações interessantes em R for Windows FAQ.

RGui

- Ao instalar o R, automaticamente também é instalada uma interface gráfica chamada RGui.
- Ao abrirmos o R, a primeira tela que veremos é a do console.
- Vamos abrir uma tela de editor de texto em “Arquivo” -> “Novo script”.
- Podemos organizar as janelas no menu “Janelas”.

RGui

- Escreveremos nossas instruções na janela do Editor.
- Podemos então executar uma linha ou um conjunto de linhas previamente selecionadas com o comando botão “Executar linha ou seleção”.

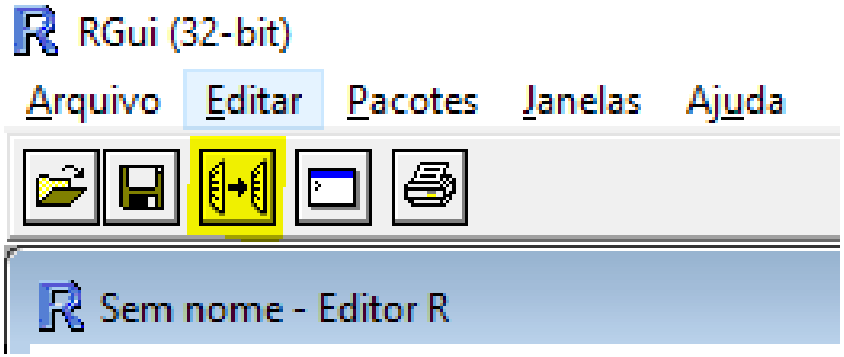

Executando algumas instruções

- Vamos digitar na janela do editor algumas instruções.
- Após cada linha, apertar o botão mencionado acima para executar o comando.
- O resultado aparecerá na janela Console.

Executando algumas instruções

- 5+5
- 10-5
- 10-20
- 3*15
- 43*12.5 (Atenção com o separador decimal!
- 14/7
- 21/45
- 34/0
- plot(1:10)

- Agora, digite q() na janela Console e tecle ENTER.

Auxiliando a programação

- Esta interface vem com o R porém é bastante limitada
- Para ganhar produtividade e facilitar a tarefa de programação, vamos utilizar uma IDE (*Integrated Development Environment* , ou Ambiente de Desenvolvimento Integrado) mais poderosa, chamada **RStudio**.

Auxiliando a programação

- O RStudio possui várias facilidades, tais como:
  - Realce contextual da linguagem;
  - Ferramentas mais avançadas de edição;
  - Recurso de *Autocomplete,* como apoio à programação;
  - Preenchimento automático de parênteses e chaves;
  - Interface intuitiva para objetos, gráficos, script, entre outras.

Auxiliando a programação

- A página principal do RStudio fica hospedada em https://www.rstudio.com/.
- A página do produto RStudio fica em https://www.rstudio.com/products/rstudio/.
- Vídeo *RStudio Overview*.
- Verifique as características do produto Desktop.
- Faça o download da versão gratuita.
- Finalmente, instale o produto!

RStudio

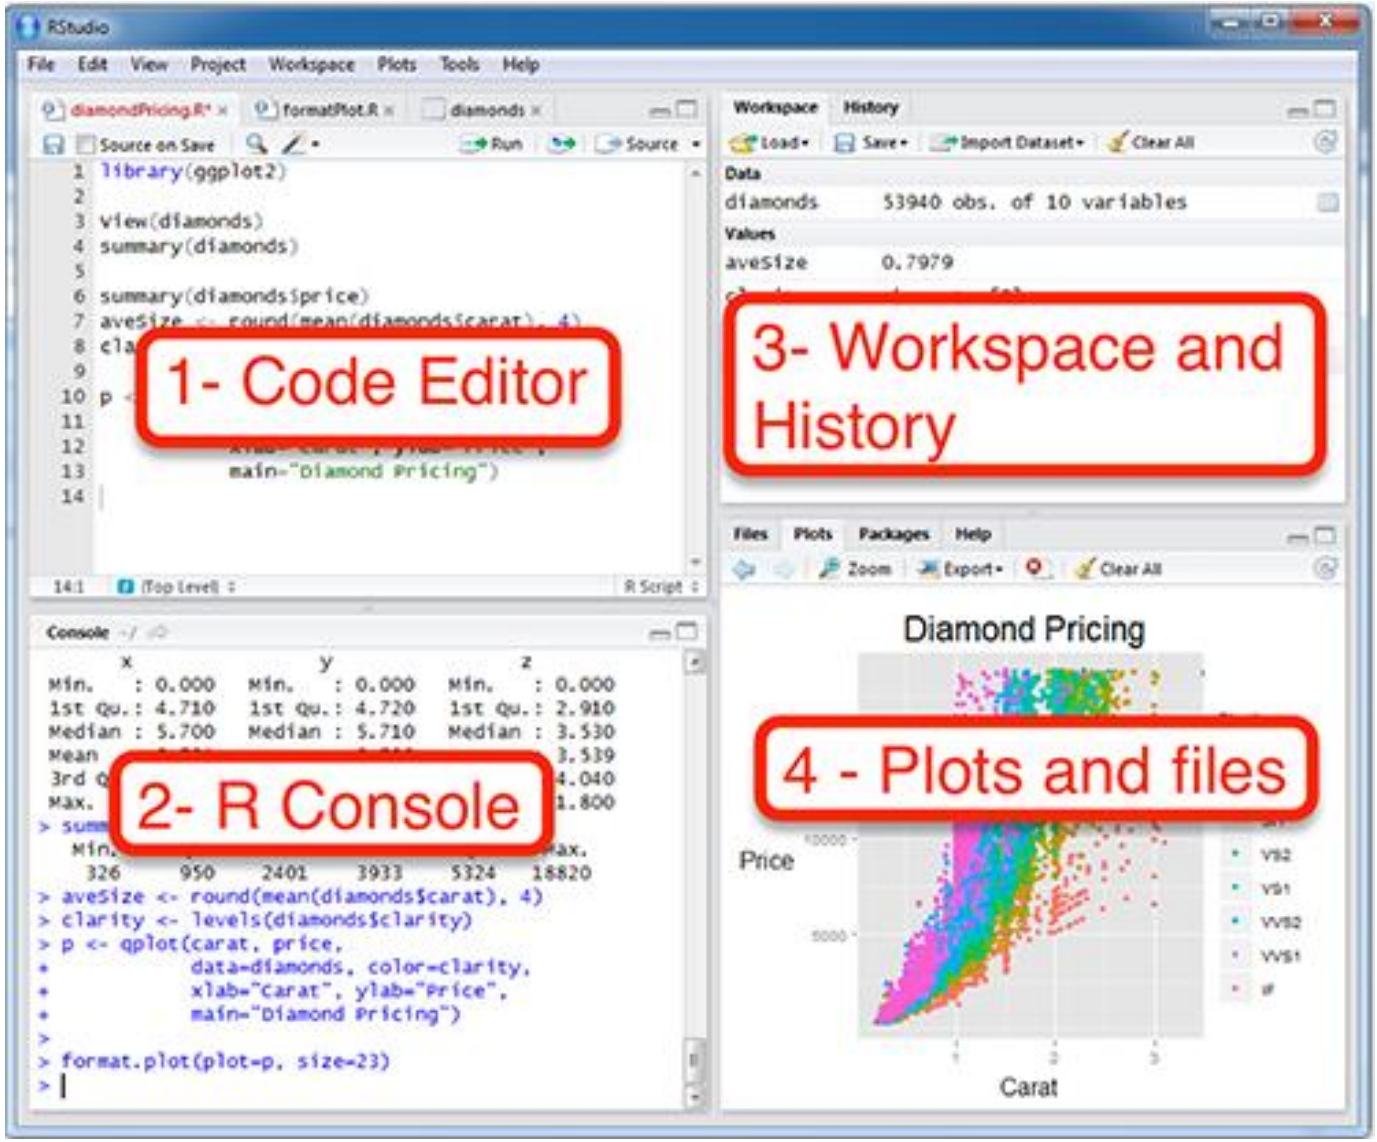

Auxiliando a programação

- Script:
  - A tela superior esquerda do RStudio é o editor de texto onde você vai escrever seus Scripts.
  - Possui, por exemplo, realce de código para facilitar a programação.
- Console:
  - No canto inferior esquerdo fica o console.
  - Nada mais é do que uma seção aberta do R, em que os comando são executados.
  - Devemos nos acostumar a escrever o código no Script ao invés de ficar escrevendo diretamente no console.

Auxiliando a programação

- Área de trabalho e histórico:
  - Ficam no canto superior direito. Os objetos criados na seção e o histórico dos comandos podem ser acessados ali.

Auxiliando a programação

- Arquivos, Gráficos, Pacotes, Ajuda:
  - Ficam no canto inferior direito. Podemos explorar pastas e arquivos diretamente do RStudio na aba “Files”;
  - Os gráficos que forem feitos apareceram na aba “Plots”.
  - Os pacotes instalados em sua máquina estão listados em “Packages”.
  - As ajudas das funções aparecem em “Help”;
  - Finalmente, o “Viewer” serve para visualização de imagens/páginas em HTML e JavaScript.

Executando algumas instruções

- Vamos agora replicar o que fizemos no RGui, agora no RStudio, e verificar o comportamento da IDE.
- Após cada linha, apertar a combinação <CTRL + ENTER> para executar o comando digitado.
  - OBS.: acionar a tecla <ENTER> apenas adiciona a linha digitada ao script, sem executá-la.
- O resultado aparecerá na janela Console e/ou na janela Plot.

Executando algumas instruções

- 5+5
- 10-5
- 10-20
- 3*15
- 43*12.5 (Atenção com o separador decimal!
- 14/7
- 21/45
- 34/0
- plot(1:10)

- Agora, digite q() na janela Console e tecle ENTER.

Executando algumas instruções

- Vamos agora fazer uma atribuição simples de um valor a uma variável e fazer uso desta variável recém criada.
- Vamos limpar a área de script e digitar as instruções abaixo (não executá-las ainda):

```
val_x <- 15
plot(1:val_x)
```

- Agora vamos selecionar as duas instruções e executá-las em sequência.
- Como vimos, podemos executar instruções ou conjunto de instruções com **CTRL+ENTER**.

Autocomplete, ajuda no contexto e ajuda geral

- O RStudio oferece os recursos de *Autocomplete* para funções e ajuda no contexto.
- Além disso, existe um sistema de ajuda bem desenvolvido dentro da IDE.
- Vamos ver como funciona!
  - **`plo + TAB`**
  - **`plot( + TAB`**
  - **`?plot`**
  - **`help(plot)`**

Atalhos

- O uso da IDE pode se tornar muito eficiente com o conhecimento dos atalhos oferecidos pela ferramenta.
- Seguem alguns dos mais úteis:

Atalhos

- **CTRL + 1**: passa o cursor para o script;
- **CTRL + 2**: passa o cursor para o console;
- **SETA PARA CIMA** (no console): acessa o histórico de comandos anteriores.
- Ao abrir um novo script:
  - **CTRL + ALT + SETA PARA ESQUERDA OU DIREITA**: Navega entre as abas de script abertas.

Atalhos

- **CTRL + SHIFT + P**: “Previous command”, roda o último comando executado;
- **CTRL + SHIFT + ENTER**: “Source”, executa o script inteiro;
- **CTRL + S**: salva o script;
- **CTRL + L**: limpa o console;
- **CTRL + F**: busca (e substituição). Aceita REGEX;
- **ALT + SHIFT + K**: lista de atalhos.

Mais ajuda

- O RStudio oferece ainda buscas dentro do sistema de Ajuda.
    - **`help.search("normal")`**
- Outra fonte importante de apoio é o conhecido site *Stack Overflow*.
    - Tópicos em português sobre o R;
    - Tópicos em inglês sobre o R.

Mais ajuda

- Um grande auxílio à busca na web por tópicos relacionados à linguagem R é o site Rseek.
- É uma ferramenta de busca no Google específica para a linguagem R devido à ambiguidade do nome da mesma.

Usando o R na AWS

- Uma boa opção para uso do R é a infraestrutura oferecida pela AWS.
- Louis Aslett oferece em seu site ótimos AMIs prontos para o uso de ambientes completos com R e RStudio na AWS.
- Até acesso ao Dropbox já vem configurado. Vale a pena utilizá-los.
- O site inclui instruções completas para a instalação.

Compreender conceitualmente a linguagem R

A linguagem R

- A linguagem R é uma linguagem de programação ‘dinamicamente tipada’, ou seja, podemos modificar os tipos de dados contidos em variáveis em programas que já estejam em execução, com isso, elimina-se a necessidade de conversões relacionadas aos tipos de dados.
- Devemos apenas tomar cuidado com a conversão na importação de dados (mais detalhes à frente).

A linguagem R

- A linguagem R é usada para manipulação de conjuntos de dados em geral, análises estatísticas e produção de documentos e apresentações centradas em dados.
- Também nos fornece uma ampla variedade de modelos lineares e não lineares, testes estatísticos, análise de séries temporais, modelos de agrupamentos, além de ser altamente extensível por meio de pacotes criados pela comunidade de usuários.

A linguagem R

- Um dos pontos fortes do R é a qualidade na geração de gráficos e visualizações dos resultados, inclusão de símbolos matemáticos e de fórmulas, quando estas passam a ser necessárias.
- Facebook e FourSquare, apenas para citar dois exemplos, utilizam a linguagem R tanto para recomendações quanto para modelagem de comportamentos dos usuários.

Pacotes

- A distribuição de códigos criados pela comunidade de usuários do R é feita por meio de pacotes.
- Um pacote é um conjunto de códigos independente que adiciona funcionalidades à linguagem.
- Ao carregar um pacote, você está adicionando suas funções ao ambiente, permitindo que você chame estas funções diretamente.

Pacotes

- Vamos tentar usar a função **mvrnorm**, que gera números aleatórios de uma a partir de uma distribuição normal (esta função é definida no pacote chamado MASS, não vem instalada como padrão).

```
# Matriz Var-Covar
Sigma<-matrix(c(10,3,3,2), nrow = 2, ncol = 2)
# Médias
mu<-c(1, 10)
#Gera 100 observações
x<-mvrnorm(n = 100, mu, Sigma)
```

Pacotes

- Fazendo a correção:

```
# Carrega a biblioteca MASS
library(MASS)
# Matriz Var-Covar
Sigma<-matrix(c(10,3,3,2), nrow = 2, ncol = 2)
# Médias
mu<-c(1, 10)
#Gera 100 observações
x<-mvrnorm(n = 100, mu, Sigma)
```

Pacotes

- Para saber o que temos disponível no ambiente R no momento, usamos o comando **`search()`**.

- Para retirar um pacote do ambiente, usamos o comando **`detach()`**.

```
detach(package:MASS)
```

Pacotes

- No caso do pacote ter uma função com o mesmo nome de uma outra já carregada, a função que prevalece é a do pacote que foi carregado por último.
- Podemos usar o nome do pacote e o operador '::' antes de chamar a função. Neste caso não há ambiguidade.

```
x <- MASS::mvrnorm(n = 100, mu, Sigma)
```

Pacotes

- Também podemos carregar pacotes pela interface RGui ou do RStudio.
- No RGui basta usar a opção de menu chamada “Pacotes”.
- No RStudio, basta usar o menu do canto inferior direito, clicando na caixa ao lado do nome do pacote.

Pacotes

- Outra opção é usar a função **`install.packages()`**.
- Ex.: o pacote **`dplyr`** é muito utilizado para manipulação de dados. Para instalá-lo e desinstalá-lo, temos os seguintes comandos:

```
# Instala o pacote
install.packages("dplyr")

# Desinstala o pacote
remove.packages("dplyr")
```

Pacotes

- Podemos instalar uma série de pacotes ao mesmo tempo:

```
install.packages(c("ggplot2", "ggthemes",
"tidyr", "reshape2", "stringr"))
```

Exemplo

- Vamos a um exemplo simples para termos uma ideia de como usar o R em análise de dados.
- Temos um conjunto de dados contendo cotações das ações de Petrobras e Vale.
- Este é apenas um exemplo motivacional, não se preocupe em saber neste momento como cada uma das instruções funcionam.

Exemplo

```
# Carregando os pacotes necessários
library(ggplot2)
library(reshape2)

# Configurando a coluna de datas corretamente
setAs("character","myDate", function(from)
as.Date(from, format="%d/%m/%Y") )

# Carregando os dados
dados <- read.csv("PETR4_VALE5.csv",
colClasses=c('myDate','numeric','numeric'),
header = TRUE, sep = ";", dec = ",")

# Ajustando os dados para gráfico
meltdados <- melt(dados,id="Date")
```

Exemplo

```
# Criando o gráfico
ggplot(meltdados,aes(x=Date,y=value,colou
r=variable,group=variable)) + geom_line()
+ theme(axis.text.x =
element_text(angle=90, hjust=1))
```

Identificar os objetos do R

Objetos

- Temos diferentes tipos de objetos no R.
- Estes objetos podem ser vetores (chamados de “variáveis”, quando o vetor tem tamanho 1), matrizes, *arrays*, *data frames* e funções.
- No dia-a-dia do uso do R nomeamos objetos para uso posterior.

Variáveis

- A atribuição de valores às variáveis na linguagem R é feita com o operador '<-', conhecido como "*assignment operator*".
  - Ex.: `x <- 20 # Atribui o valor 20 à variável x`
- Em muitos casos o operador '=' é similar ao '<-', porém nem sempre este é o caso.
  - Ex.: `y = 25 # Atribui o valor 25 à variável y`

Variáveis

- Recomenda-se no entanto o uso do operador ‘<-’ sempre pois é exclusivo para atribuição de valores.
- O operador ‘=‘ tem um uso diferenciado em alguns casos e veremos isso mais adiante.

Variáveis

- O operador ‘<-’ nada mais é que uma função de atribuição. Uma outra função que tem o mesmo objetivo é **`assign("nome_Objeto", valor_Objeto)`**.

  - Ex.: **`assign("z", 30) # cria a variável z com o valor 30`**

Variáveis

- Após a atribuição de valores podemos operar com as variáveis recém criadas.

```
x + y + z # soma x,y,z

x/z # divide x por z

y * z # multiplica y por z

t <- x * y + z # cria t com o resultado
                 de (x*y+z)
```

Variáveis

- A linguagem R é sensível ao uso de maiúsculas e minúsculas, portanto isso deve ser levado em consideração ao nomearmos variáveis.
- **Variáveis com os nomes `ab`, `Ab`, `aB` e `AB` são diferentes!**

Variáveis

- Nomes de variáveis no R podem conter combinações arbitrárias de números, textos, assim como ponto (.) e sublinhado (_).
- Porém, os nomes não podem começar com números ou sublinhado.

  - `xp_t2.F34 <- "variável válida"`
  - `_problema <- 2500`
  - `5_outro_problema <- 5000`

Tipos de variáveis

Tipo de variável	Exemplos	Uso

Lógica	TRUE, FALSE	`v <- TRUE`
		`print(class(v))`
		Produz o seguinte resultado
		`[1] "logical"`

Numérica	12.3, 5, 999	`v <- 23.5`
		`print(class(v))`
		Produz o seguinte resultado
		`[1] "numeric"`

Inteira	2L, 34L, 0L	`v <- 2L`
		`print(class(v))`
		Produz o seguinte resultado
		`[1] "integer"`

Tipos de variáveis

Tipo de variável	Exemplos	Uso

Complexa	3 + 2i	`v <- 2+5i`
		`print(class(v))`
		Produz o seguinte resultado
		`[1] "complex"`

Texto	"bom", "TRUE", '23.4'	`v <- "TRUE"`
		`print(class(v))`
		Produz o seguinte resultado
		`[1] "character"`

Raw	"Hello" is stored as 48 65 6c 6c 6f	`v <- charToRaw("Hello")`
		`print(class(v))`
		Produz o seguinte resultado
		`[1] "raw"`

Trabalhando com objetos

- Para listar todos os objetos que estão na área de trabalho, utilizamos a função **`ls()`**.
- Já a função **`rm(objeto)`**, remove um objeto da área de trabalho.
- Para salvar uma cópia de todos os objetos criados podemos utilizar a função **`save.image()`**.
- Para limparmos a área de trabalho usamos a instrução **`rm(list = ls())`**.
- Para carregarmos um arquivo com os objetos usamos a função **`load()`**.

Vetores

- Possui uma dimensão e um tipo de dado.
- Sequência de variáveis de diversos tipos. Não permite mistura de dados (coerção - próximo slide).

```
vetor1 <- c(1:10)
vetor1
length(vetor1)
mode(vetor1)
class(vetor1)
```

Coerção

- Um vetor somente pode ter elementos de uma única classe.
- Não é possível, por exemplo, misturar textos com números.

Coerção

- Quando misturamos elementos de classes diferentes em um vetor, o R faz a coerção do objeto para uma das classes, obedecendo uma ordem de prioridade:

$$lógico < inteiro < numérico < complexo < texto$$

Coerção - Exemplos

```
x <- c(1, 2, 3L)
class(x)
[1] "numeric"

x <- c(1, 2, 3L, 4i)
class(x)
[1] "complex"

x <- c(1, 2, 3L, 4i, "5")
class(x)
[1] "character"
```

Coerção

- Podemos forçar a conversão de um vetor de uma classe para outra com as funções **`as.xxx`** (sendo “xxx” a classe).
- Porém, nem sempre essa conversão faz sentido, e pode resultar em erros ou Nas (“Not Applicable”).

Coerção - Exemplos

```
numero <- c(546.90, 10, 789)
as.character(numero) # Vira texto
[1] "546.9" "10" "789"

texto <- c("aspas duplas", 'aspas
simples', "aspas 'dentro' do texto")
as.numeric(texto) # Não faz sentido
[1] NA NA NA

logico <- c(TRUE, FALSE, TRUE)
as.numeric(logico) # TRUE->1, FALSE->0
[1] 1 0 1
```

Concatenação

- E o que é aquele '`c`' antes dos parênteses em várias das atribuições nos exemplos anteriores?

- É uma função nativa do R usada para criar um vetor a partir de valores explícitos. Se quisermos criar um sequência de valores, utilizamos o operador '`:`', como nos exemplos da função `plot()` acima.

Matriz

- Possui duas dimensões e um tipo de dado.
- Coleção de vetores em linhas e colunas, sendo que todos os vetores devem ser do mesmo tipo de dado.

```
matriz1 <- matrix(1:10, nrow =2)
matriz1
length(matriz1)
mode(matriz1)
class(matriz1)
```

Array

- Possui duas ou mais dimensões e um tipo de dado.
- Similar às matrizes, porém permite mais dimensões.

```
array1 <- array(1:5, dim=c(3,3,3))
array1
length(array1)
mode(array1)
class(array1)
```

Data frames

- Permite dados de diferentes tipos.
- É uma matriz com diferentes tipos de dados.

```
View(iris)
length(iris)
mode(iris)
class(iris)
```

Listas

- Coleção de diferentes objetos.
- Diferentes tipos de dados são possíveis e comuns.

```
lista1 <- list(a=matriz1,
b=vetor1)
lista1
length(lista1)
mode(lista1)
class(lista1)
```

Funções

- Em R, também são vistas como objetos.

```
func1 <- function(x) {
  var1 <- x * x
  return(var1)
}

func1(5)
class(func1)
```

Resumo

Objeto	Tipos	Permite mistura de tipos?
Vetor	Numérico, texto, complexo ou lógico	Não
Matriz	Numérico, texto, complexo ou lógico	Não
Array	Numérico, texto, complexo ou lógico	Não
Data frame	Numérico, texto, complexo ou lógico	Sim
Lista	Numérico, texto, complexo ou lógico	Sim
Funções	Expressões	N/A

Resumo

Vector

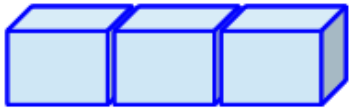

Matrix

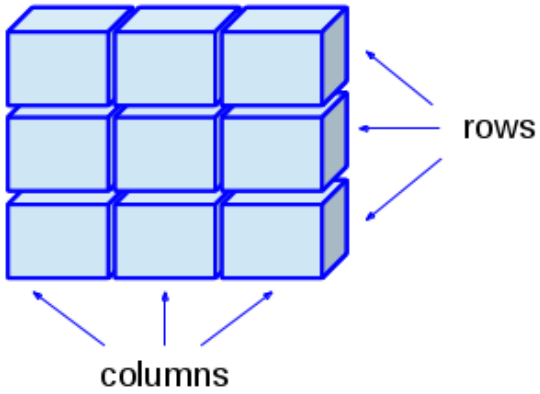

Array

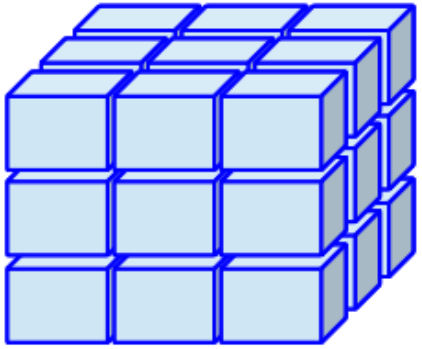

Data Frame
(Table)

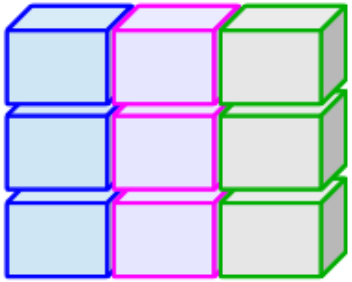

Lists