Big Data Analytics

Transformações de dados

Agenda

- Transformações de dados

Transformações de dados

Transformações de dados

- Focaremos nosso estudo nesta etapa nas funções de transformação de dados.
- São funções que manipulam dataframes, talvez o mais importante objeto da linguagem R!

Funções *apply*

- **Aplicar função nas dimensões**: a função `apply()` aplica funções nas linhas, colunas ou outras dimensões de uma matriz, *dataframe* ou *array*.

Funções *apply*

- **Aplicar função em listas**: para aplicar uma função a cada elemento de uma lista, podemos usar **`lapply()`** ou **`sapply()`**. A diferença entre elas é o formato do resultado.
  - **`lapply()`** retorna uma lista;
  - **`sapply()`** retorna um vetor.

Funções *apply*

- **Aplicar funções em múltiplos elementos**: a função **`mapply()`** pode ser considerada uma versão multivariada do **`sapply()`**.
- A **`mapply()`** deve ser usada quando você tem várias estruturas de dados diferentes(e.g. vetores, listas) e você quer aplicar a função para os primeiros elementos de cada e então os segundos, etc. Retorna um vetor ou array.

Funções *apply*

- **Repetir código em simulações**: para isso temos a função `replicate()`, que replica uma expressão diversas vezes.

Quando usar?

- O **`sapply()`** é para uso interativo. Quando você está explorando uma base de dados, o **`sapply()`** facilita seu trabalho tentando simplificar o resultado da operação.
- No entanto, o **`sapply()`** não te dá sempre o mesmo resultado (às vezes pode ser um vetor, às vezes uma lista), e isso pode ser perigoso para usar em funções.

Quando usar?

- A função **`lapply()`** é mais previsível que o **`sapply()`**, ela sempre vai te retornar uma lista.
- Neste caso, você vai ter o trabalho de simplificar o resultado manualmente, mas não terá a surpresa de vir um resultado em um formato diferente do que você esperava.

Função *replicate*

- A função **`replicate()`** é uma função de conveniência para repetir a execução de uma expressão diversas vezes no R.
- É bastante utilizada para simulações, como por exemplo a simulação de Monte Carlo.

Função *mapply*

- A função **`mapply()`** pode ser considerada uma **`sapply()`** "multivariada".
- Exemplo: a instrução **`mapply(funcao,x,y,z)`** é equivalente a:

```
funcao(x[1], y[1], z[1])
funcao(x[2], y[2], z[2])
funcao(x[3], y[3], z[3])
funcao(x[4], y[4], z[4])
                ...
funcao(x[n], y[n], z[n])
funcao(x[n], y[n], z[n])
```

Resumo

- **`apply()`**: aplica função nas dimensões (linha, coluna, etc.) do objeto.
- **`lapply()`**: aplica função em todos elementos do objeto. Retorna uma lista.
- **`sapply()`**: similar a **`lapply()`** mas tenta simplificar resultado.
- **`mapply()`**: versão multivariada do **`sapply()`**. Aplica função a todos elementos de vários objetos.
- **`replicate()`**: replica expressão um número pré-estabelecido de vezes.

Funções *apply*

- Exemplos no RStudio.

Manipulação de *dataframes*

- Vamos ver agora mais instruções de manipulação de dataframes.

- Para isso, vamos carregar uma base de dados de valores de imóveis no Rio de Janeiro.

- Passemos ao RStudio para executar as operações.

DAC ou SAC

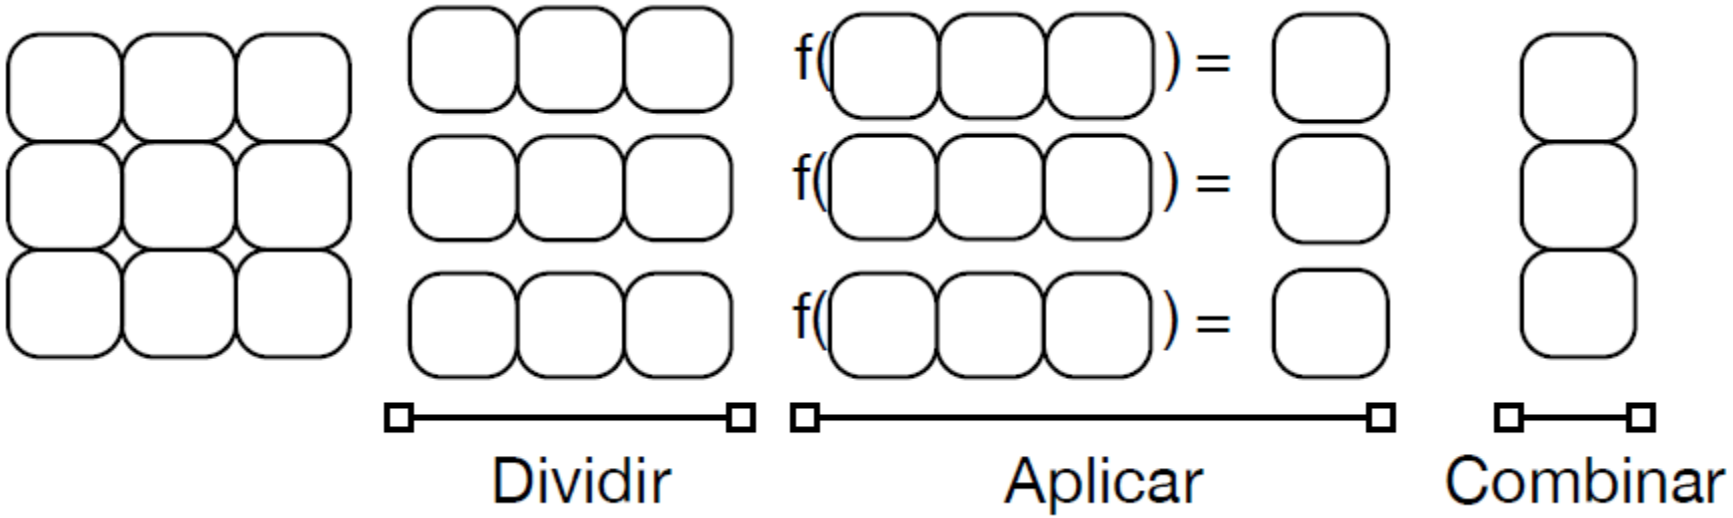

DAC ou SAC

- Funções **`apply()`** também trabalham assim.
- Ao aplicar uma função por linhas, estamos dividindo a matriz por uma das dimensões, aplicando funções a cada uma das partes e combinando os resultados em um vetor.
- Voltando ao RStudio.

Outliers

- O que está estranho com a resposta abaixo:

```
> lapply(alug_venda, summary)
$aluguel
Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   0    1300    2300    9419    5500 7000000

$venda
Min.    1st Qu.     Median       Mean    3rd Qu.       Max.
   0     485000     980000    1634000    1800000 828600000
```

Outliers

- A grande diferença entre média e mediana pode indicar a presença de *outliers*.
- Vamos então limpar o dataframe, retirando os valores muito discrepantes de preço por metro quadrado:
  - Venda, valores abaixo de 3000 ou acima de 20000.
  - Aluguel, valores abaixo de 25 ou acima de 60.

- Voltando ao RStudio.

O pacote *dplyr*

- As funções da família **`apply`** e similares nos permite fazer praticamente todas as operações para preparação, exploração e análise de dados.
- Entretanto, essas funções podem deixar a desejar em termos de performance.
- Existe um pacote bastante rápido para manipulação de *dataframes*, de sintaxe simples, chamado **`dplyr`**.
- É provável que, na grande maioria dos casos, o pacote **`dplyr`** seja a solução mais rápida e eficiente.

Resumo das funções principais

- **`select`**: seleciona uma ou mais colunas de um *dataframe*. Por exemplo, selecionar a coluna de preços.
- **`filter`**: filtra um *dataframe* com vetores lógicos. Por exemplo, filtrar valores de pm2 menores ou maiores que determinado nível.
- **`arrange`**: orderna o *dataframe* com base em uma coluna. Por exemplo, ordenar do maior para o menor pm2.

Resumo das funções principais

- **`mutate`**: cria uma nova coluna. Por exemplo, criar a coluna pm2 como preco/m2.
- **`group_by`**: agrupa um *dataframe* por índices. Por exemplo, agrupar os dados de imóveis por bairro e número de quartos.
- **`summarise`**: utilizado normalmente após o **`group_by`** para calcular valores por grupo. Por exemplo, tirar a média ou mediana do preço por bairro.

Operador %>%

- Além das funções anteriores (e outras), o pacote **`dplyr`** inclui também o uso do operador "*pipe*" , tão conhecido no ambiente Linux, indicado na linguagem R por `%>%`.
- Este operador faz com que você possa escrever **`x %>% f()`** ao invés de **`f(x)`**.
- Na prática, você vai poder escrever o código de manipulação dos dados da mesma forma que você pensa nas atividades.

Exemplo 1

- Vamos pegar a base de dados “unicos”, filtrar apenas os dados de venda de “apartamento”. Vamos então agrupar os dados por “bairro”, calcular as medianas do “preço”, “m2” e “pm2” e o número de observações. Finalmente, vamos filtrar apenas os grupos com mais de 30 observações e ordenar de forma decrescente com base na mediana de “pm2”.

Exemplo 2

- Agora, vamos usar a base de dados “unicos” para fazer uma busca de apartamentos. Estamos procurado apartamento nos bairros A e D, para aluguel, com preço menor que R$2.200,00.

Exemplo 3

- Finalmente, vamos pegar a base de dados “unicos”, filtrar apenas os dados coletados de “apartamento”, selecionar as colunas “bairro” e “preco”, criar uma coluna “pm2=preco/m2” e ordenar os dados de forma decrescente por “pm2”.

A função *merge*

- A função **`merge()`** serve para combinar *dataframes*.
- Ela tenta identificar quais são as colunas identificadoras em comum entre dois *dataframes* para realizar a combinação.
- É similar ao **`join`** do SQL.

A função *merge*

- Por meio dos parâmetros **`all`**, **`all.x`**, **`all.y`** define-se o tipo do **`merge`**.
  - O default é FALSE e é equivalente ao “natural join” do SQL;
  - “all” é equivalente ao “outer join”;
  - “all.x” é equivalente ao “left outer join”;
  - “all.y” é equivalente ao “right outer join”.

A função *merge*

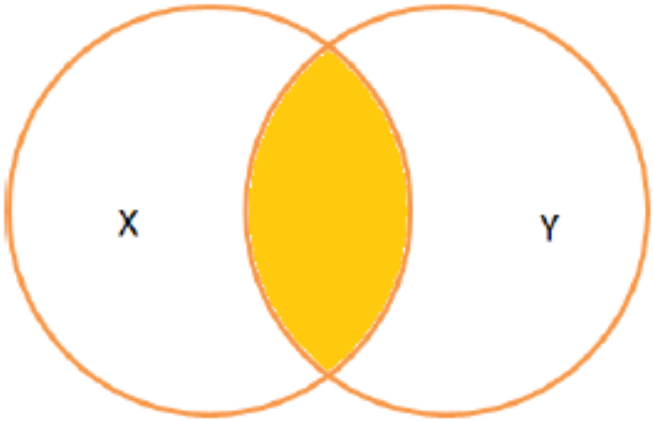

all = FALSE

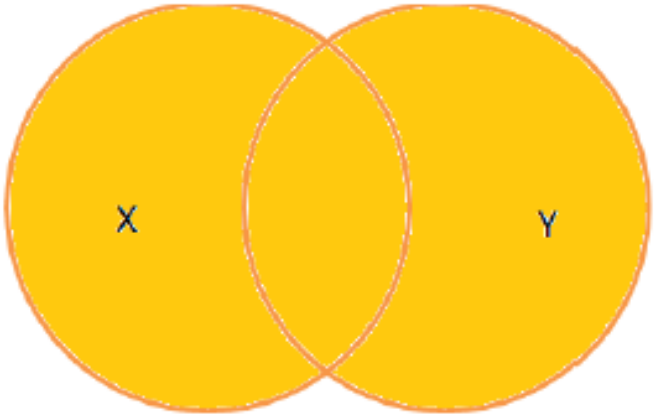

all = TRUE

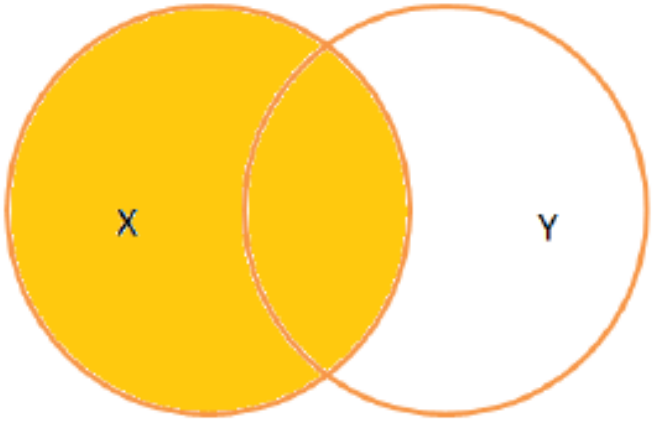

all.x = TRUE

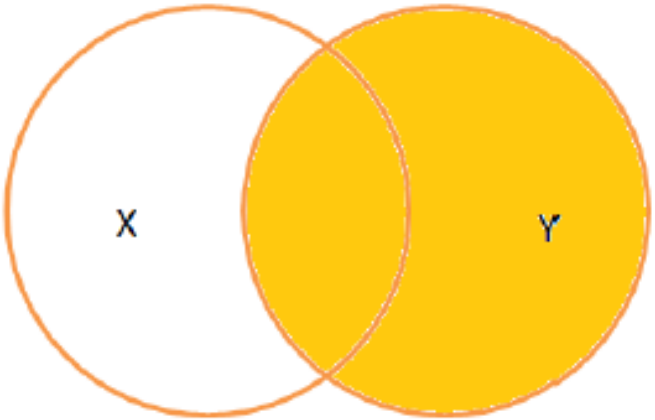

all.y = TRUE

Exemplo

- Vamos usar a instrução **`aggregate()`** para calcular a mediana do pm2 separadamente para aluguel e para venda. Depois vamos usar o **`merge()`** para juntar os dados.

Fazendo *merge* no *dplyr*

- O pacote **`dplyr`** também vem com funções de **`merge`** (neste caso, chamadas **`join`**).

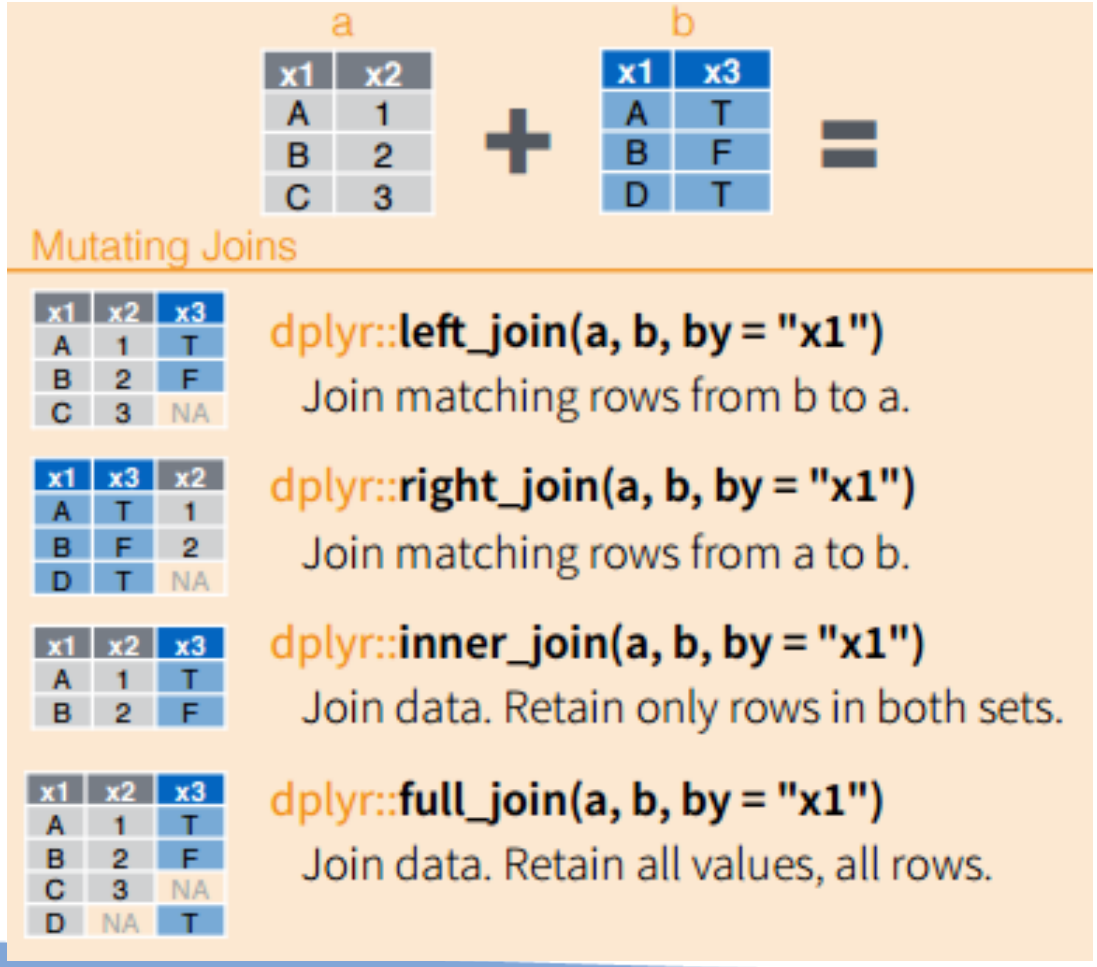

Fazendo *merge* no *dplyr*

- Exemplos no RStudio.

Formatos *wide* x *long*

- A tabela gerada pela instrução **`tapply()`** é um exemplo de tabela no formato *wide*, onde as colunas representam grupos.
- Já o formato gerado pela **`aggregate()`** ou pelo **`dplyr`** é um exemplo de formato *long*, onde temos várias colunas identificadoras e apenas uma coluna de valores.
- É bastante comum usar dados no formato *long* em pacotes de visualização, como o **`ggplot2`** ou **`lattice`**.
- O formato *wide*, por sua vez, é bastante utilizado em apresentação de tabelas.
- Então, muitas vezes precisaremos transformar nossos dados de um formato para o outro.

O pacote *reshape2*

- A função **`melt()`** transforma dados no formato *wide* para o formato *long*.
- As funções **`acast()`** e **`dcast()`** transforma dados no formato *long* para o formato *wide*. A primeira retorna um *array* e a segunda um *dataframe*.
- Exemplos no RStudio.

O pacote *tidyr*

- O **`tidyr`** é um pacote que executa diversas tarefas de manipulação de dados, entre elas transformar do formato *wide* para o formato *long* e vice-versa.
- No entanto, este pacote só opera em *dataframes*.
- Exemplos no RStudio.

Tidyverse

- É uma coleção de pacotes R que funcionam de forma conjunta ou como parte de um pipeline de análise de dados (outro link na imagem abaixo).